

FIAP

PÓS-GRADUAÇÃO EM IA PARA DEVS

TECH CHALLENGE — FASE 1

MODELO DE CLASSIFICAÇÃO DE CÂNCER DE MAMA

Grupo 13

Integrantes:

Adolfho Athyla de Almeida Beserra

Andre Paulo Pasquetti

Heloysa dos Santos Arruda

Kauanny Tenorio Felix da Silva

Nicanor da Costa Bondarenco

São Paulo

2026

TECH CHALLENGE — FASE 1

MODELO DE CLASSIFICAÇÃO DE CÂNCER DE MAMA

Relatório técnico apresentado à Pós-Graduação em IA para Devs, como parte das atividades do Tech Challenge — Fase 1.

São Paulo
2026

RESUMO

Este trabalho apresenta o desenvolvimento de uma solução de Machine Learning para classificação de câncer de mama, utilizando o dataset Wisconsin Diagnostic Breast Cancer (WDBC). Foram realizadas etapas de análise exploratória, limpeza, pré-processamento, treinamento e avaliação de modelos de classificação. Foram comparados Logistic Regression, K-Nearest Neighbors (KNN) e Random Forest, além de experimentos com RobustScaler e PCA. O Random Forest sem PCA apresentou Accuracy de 97,37%, Precision de 100,00%, Recall de 92,86%, F1-score de 96,30% e ROC-AUC de 99,29%, sendo selecionado como modelo final no notebook. O projeto possui finalidade acadêmica e experimental e não se destina ao diagnóstico médico.

Palavras-chave: Machine Learning; câncer de mama; classificação; análise de dados; Random Forest.

SUMÁRIO

1 INTRODUÇÃO	5
2 CONTEXTUALIZAÇÃO DO PROJETO	5
3 OBJETIVOS	5
3.1 Objetivo geral	5
3.2 Objetivos específicos	5
4 DATASET E PROBLEMA DE CLASSIFICAÇÃO	6
5 METODOLOGIA	6
5.1 Análise exploratória	6
5.2 Limpeza e pré-processamento	6
5.3 Separação entre treino e teste	6
5.4 Modelagem	7
5.5 Estratégias alternativas: RobustScaler e PCA	7
5.6 Métricas de avaliação	7
6 RESULTADOS E DISCUSSÃO	7
6.1 Comparação dos modelos	7
6.2 Matriz de confusão	8
7 CONCLUSÃO	8
8 REPOSITÓRIO E VÍDEO	9
REFERÊNCIAS	9

1 INTRODUÇÃO

O Tech Challenge — Fase 1 propõe a aplicação integrada de conhecimentos de Inteligência Artificial, Data Science e tecnologias relacionadas em um problema voltado à saúde e segurança das mulheres. Dentro desse contexto, escolhemos trabalhar com a classificação de câncer de mama utilizando dados estruturados e técnicas de Machine Learning.

O projeto busca desenvolver uma solução experimental capaz de classificar amostras como benignas ou malignas, explorando o processo de análise de dados, preparação, modelagem e avaliação.

2 CONTEXTUALIZAÇÃO DO PROJETO

A proposta do desafio apresenta o diagnóstico de câncer de mama como uma das possibilidades de aplicação e orienta a utilização de bases relacionadas à saúde feminina. A partir dessa proposta, foi selecionado o Wisconsin Diagnostic Breast Cancer (WDBC), com o objetivo de investigar se diferentes algoritmos conseguem identificar padrões associados às duas classes de diagnóstico.

3 OBJETIVOS

3.1 Objetivo geral

Desenvolver e avaliar uma solução inicial de Machine Learning capaz de classificar amostras do dataset Wisconsin Diagnostic Breast Cancer em benignas ou malignas, estabelecendo uma base experimental para apoiar processos de triagem e análise de risco relacionados ao câncer de mama.

3.2 Objetivos específicos

- Explorar as características e a qualidade do dataset utilizado.
- Realizar limpeza e pré-processamento dos dados.
- Analisar relações e correlações entre as variáveis.
- Separar os dados em conjuntos de treinamento e teste.
- Treinar e comparar diferentes técnicas de classificação.

- Avaliar os modelos utilizando métricas adequadas ao problema.
- Analisar a matriz de confusão do modelo selecionado.
- Discutir os resultados e as limitações da solução.

4 DATASET E PROBLEMA DE CLASSIFICAÇÃO

Foi utilizado o Wisconsin Diagnostic Breast Cancer (WDBC), dataset público relacionado à saúde feminina. O problema tratado é de classificação binária: a partir das características numéricas das amostras, o modelo deve classificar o diagnóstico como benigno (B) ou maligno (M).

5 METODOLOGIA

5.1 Análise exploratória

A análise exploratória contemplou estrutura do dataset, tipos das variáveis, estatísticas descritivas, valores ausentes, registros duplicados, distribuição da variável alvo, visualizações e análise de correlação. A variável diagnosis apresentou 357 amostras benignas (62,7%) e 212 malignas (37,3%).

5.2 Limpeza e pré-processamento

As colunas Unnamed: 32 e id foram removidas. A variável diagnosis foi codificada com LabelEncoder, resultando em B = 0 e M = 1. Para o escalonamento das variáveis, foi utilizada principalmente a técnica StandardScaler, além de uma abordagem alternativa com RobustScaler.

5.3 Separação entre treino e teste

Os dados foram separados em treinamento e teste utilizando 80% para treinamento e 20% para teste, com random_state igual a 42 e estratificação pela variável alvo.

5.4 Modelagem

Foram avaliados Logistic Regression, K-Nearest Neighbors (KNN) e Random Forest. A comparação permitiu avaliar diferentes abordagens para o mesmo problema de classificação.

5.5 Estratégias alternativas: RobustScaler e PCA

Também foi realizada uma abordagem utilizando RobustScaler e PCA antes da classificação, com o objetivo de avaliar o efeito de um escalonamento mais robusto e da redução de dimensionalidade.

5.6 Métricas de avaliação

Os modelos foram avaliados por Accuracy, Precision, Recall, F1-score e ROC-AUC, além de matriz de confusão e classification report.

6 RESULTADOS E DISCUSSÃO

6.1 Comparação dos modelos

	Model	Accuracy	Precision	Recall	F1 Score	ROC-AUC
1	Random Forest	0.973684	1.000000	0.928571	0.962963	0.992890
3	Logistic Regression + RobustScaler + PCA	0.973684	1.000000	0.928571	0.962963	0.997354
0	Logistic Regression	0.964912	0.975000	0.928571	0.951220	0.996032
2	K-Nearest Neighbors	0.956140	0.974359	0.904762	0.938272	0.982308
4	Random Forest + RobustScaler + PCA	0.938596	0.948718	0.880952	0.913580	0.985450
5	KNN + RobustScaler + PCA	0.938596	0.972973	0.857143	0.911392	0.982308

Tabela 1 — Comparação dos modelos avaliados.

O Random Forest sem PCA apresentou 97,37% de Accuracy, 100,00% de Precision, 92,86% de Recall, 96,30% de F1-score e 99,29% de ROC-AUC. A Logistic Regression com RobustScaler e PCA apresentou a mesma Accuracy, Precision, Recall e F1-score, com ROC-AUC de 99,74%. No notebook, o Random Forest sem PCA foi selecionado como modelo final.

6.2 Matriz de confusão

Para o Random Forest, a matriz de confusão apresentou 72 verdadeiros negativos, 39 verdadeiros positivos, nenhum falso positivo e três falsos negativos. Portanto, 111 das 114 amostras do conjunto de teste foram classificadas corretamente.




Tabela 2 — Matriz de confusão do Random Forest.

7 CONCLUSÃO

Foi desenvolvido uma solução inicial de Machine Learning para classificação de câncer de mama, percorrendo as etapas de exploração, preparação dos dados, modelagem e avaliação. A comparação entre diferentes algoritmos mostrou desempenho elevado no conjunto de teste.

O Random Forest foi selecionado como modelo final no notebook, com 97,37% de Accuracy e 99,29% de ROC-AUC. Como evolução, pretendemos ampliar a análise

de explicabilidade, testar validações adicionais e aprofundar a avaliação da generalização do modelo.

8 REPOSITÓRIO E VÍDEO

O projeto completo está organizado em repositório Git, contendo o notebook, README, arquivo de dependências e demais arquivos necessários para reprodução do trabalho.

Repositório: <https://github.com/NicoBondarenco/tech-challenge-11iadt-fase-01>

Link do vídeo de apresentação: <https://youtu.be/3r7pjXJOXdo>

REFERÊNCIAS

TECH CHALLENGE. Fase 1 — Inteligência Artificial, Data Science e Tecnologias relacionadas. Proposta fornecida para o desenvolvimento do projeto.

Diagnostic Breast Cancer (WDBC). Dataset público utilizado no projeto, conforme indicação da proposta do Tech Challenge.
<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>.